Chapitre 1 :
Langages formels

Sources :
- Olivier Carton, Langages formels, calculabilité et complexité
- Sakarovitch, Elements of automation theory

Table des matières

N.1 Introduction 1

I Mots et alphabets 1
- I.1 Définition 1
- I.2 Structuration de Σ^* 3

II Langages 4
- II.1 Mauvaise nouvelle 5
- II.2 Opérations sur les langages 6
- II.3 Langages et expressions rationnelles (= régulières) 7

III Langages locaux 10
- III.1 Définitions 10
- III.2 Stabilité des langages locaux 11
- III.3 Expressions rationnelles linéraires 13

N.1 Introduction

Le but est d'étudier des ensembles de mots : les langages. Ceci permet entre autre la reconnaissance de motifs et la compilation, en particulier l'analyse lexicale et syntaxique

Fondamentalement, par exemple, tout prolbème de décision revient à tester l'appartenance d'un mot à un langage.

I Mots et alphabets

I.1 Définition

Définition

Un **alphabet** est un ensemble fini de symboles, appelés **lettres**

Remarque

Dans ce cours, les alphabets seront noté Σ en priorité, puis Γ, etc…

Exemple 1: Les ensembles suivants sont tous des alphabets :
{A, T, C, G}
{0, 1}
{(,)}
{« L'ensemble des caractères ASCII »}
{□, ∿, ℵ, ⚅, ∇}
{let, in, for, while, else, if, ;}

Dans le dernier, « let » n'est pas un mot mais une simple lettre

Définition

Un **mot** sur un alphabet Σ est une suite finie (eventuellement vide) de lettres de Σ

Notation

On note
- Σ^* l'ensemble des mots sur Σ
- ε le mot vide
- Σ^+ l'ensemble $\Sigma^*\{\varepsilon\}$ des mots non vides sur Σ

Avertissement

C'est une très mauvaise idée de mettre le symbole ε dans un alphabet (collision avec ε pour le mot vide)

Notation

Si $m_1, ..., m_k$ sont des lettres de Σ, le mot $(m_1, ..., m_k)$ se nbotre $m_1...m_k$

Proposition 1: Si Σ est non vide, Σ^* est infini

Démonstation: Σ est non vide donc il existe $a \in \Sigma$.
Ainsi, $\{\varepsilon, a, aa, aaa, ...\} = \{a^n, n \in \mathbb{N}\} \subset \Sigma^*$

Définition

Si m est un mot sur Σ et $a \in \Sigma$

- La **longueur** du mot m, note $|m|$ est son nombre de lettres
- Le nombre d'occurence de a dans m est noté $|m|_a$

Exemple 2: Pour le mot $m = (()(()$ sur $\Sigma = \{(,)\}$
$|m| = 6, |m|_(= 4$

I.2 Structuration de Σ^*

On introduit sur Σ^* l'opération de concaténation

Définition

Si $u = u_1...u_n$ et $v = v_1...v_m$ sont des mots sur Σ, la **concaténation** de u et v est le mot $u_1...u_n v_1...v_m$

On peut trouver les notation $u \cdot v$ pour la concaténation mais elle est souvent omise.

Proposition 2: $(\Sigma^*, \cdot)$ est un monoïde

Démonstation:
$\cdot$ est interne
$\cdot$ admet un élément neutre ε
$\cdot$ est associative : $(uv)w = u(vw)$

L'opération de concaténation permet de définir les puissances d'un mot

Définition

Si $u \in \Sigma^*$, $u^0 = \varepsilon$ et $\forall n \in \mathbb{N}, u^n + 1 = u \cdot u^n$

Proposition 3:
$u^n u^m = u^{n+m}$
$(u^n)^m = u^{n \times m}$

Définition

Si $m = m_1..m_n$ et $u = u_1...u_m$ sont des mots sur Σ, on dit que :
- u est un **préfixe** de m si $\exists v \in \Sigma^*, m = uv$
- u est un **suffixe** de m si $\exists v \in \Sigma^*, \text{ù} = vu$
- u est un **facteur** de m si $\exists v, w \in \Sigma^*, m = vuw$
- u est un **sous-mots** de m si u est une suite extraire de m

Remarque

Pour exclure les cas « limites », on utilise souvent les termes préfixe ou suffixe stricte ou préfixe et suffixe propre.

Avertissement

- Les définitions de ces termes peuvent varier selon le contexte
- Ne pas confondre facteur et sous-mot

Proposition 4:
- Si u est un préfixe ou suffixe de m, il en est aussi facteur
- Si u est facteur de m, il en est aussi sous-mot
- Toutes les réciproques sont fausses

Exemple 3: Pour le mot hippopomonstrosesquipedaliophobie :
- hippo est un préfixe
- phobie est un suffixe
- monstro est un facteur
- strophe est un sous-mot

II Langages

Dans cette partie, Σ estu n alphabet non-vide

Définition

Un **langage** sur Σ est une partie de Σ^*, c'est à dire un ensemble de mots

Exemple 4: Sur $\Sigma = \{a, b\}$, les ensmelbes suivants sont des languages

{a, ε, bab}
Σ^*

$\emptyset$
$\{\varepsilon\}$
$\{\mathrm{a}^n\mathrm{b}^n \mid n \in \mathbb{N}\} = \{\varepsilon, \mathrm{ab}, \mathrm{aabb}, \mathrm{aaabbb}, \ldots\}$

Sur $\Sigma = \{$« l'ensemble des caractères ASCII »$\}$

{« codes des fonctions OCaml de type `int -> unit` qui remine sur toute entrée »}
{code des fonctions OCaml qui sont syntaxiquement correctes}

De manière générale, pour définir un langage :
- on énumère les mots
- on décrit une propriété que doivent vérifier les mots
- on définit des règles de construction

Par exemplen le langage de Dyck des expressions bien parenthésées sur $\Sigma = \{(,)\}$ est défini par $\varepsilon \in \mathcal{D}$, $u, v \in \mathcal{D}, (u)v \in \mathcal{D}$

II.1 Mauvaise nouvelle

Proposition 5: Il y a un nombre infini indénombrable de langages

Démonstation: Montrons que $\mathcal{P}(\Sigma^*)$ est non dénombrable

1. Montrer que Σ^* est dénombrable
2. Montrer que E et $\mathcal{P}$(E) ne peuvent pas être en bihection si E est un ensemble

1. Σ^* est dénombrable car $\Sigma^* = \bigcup_{n\in\mathbb{N}} \{m \in \Sigma^* \mid |m| = n\}$. Σ^* est donc une union dénombrable d'ensembles finis donc est dénombrable
2. Supposons par l'absurde qu'il existe une sujection $\varphi : E \to \mathcal{P}(E)$

   On note $X = \{x \in E \mid x \notin \varphi(x)\} \subset \mathcal{P}(E)$

   Comme $X \subset \mathcal{P}(E)$ et φ est une surjection, il existe $x_0 \in E$ tel que $X = \varphi(x_0)$

   - Si $x_0 \in X$, alors $x_0 \notin \varphi(x_0) = X$
   - So $X_0 \notin X = \varphi(x_0)$, alors par définition de $X, x_0 \in X$

   Ainsi, il y a contracition dans tous les cas : φ n'existe pas et donc, comme il n'y a pas de surjections de E sur $\mathcal{P}$(E), il n'y pas de bijection entre les deux

Aisni, Σ^* est en bijection avec $\mathbb{N}$ et pas avec $\mathcal{P}$(E), donc $\mathcal{P}$(E) n'est pas en bijection avec $\mathbb{N}$ et $\mathcal{P}$(E) n'est pas dénombrable.

Conséquence

Il existe un nombre dénombrable d'algorithme, car il fomre un langage sur Σ^* avec Σ les caractères autorisés, mais il existe un nombre indénombrable de langages. Par conséquent, il existe des langages (une infinité indénombrable) pour lesquels le test d'appartenance à ce langage ne peut pas être fait algorithmiquement

II.2 Opérations sur les langages

Les langages sont des ensembles donc on peut faire toutes les opérations ensemblistes usuelles dessus

Avertissement

L'union est noté soit + soit |

Il est également possible de construire des opérations sur les langages à partir des opérations sur les mots

Définition

Si L et L' sont des langages sur Σ

- La **concaténation** de L et L' est LL' $= \{\omega \in \Sigma^* \mid \exists (u, v) \in L \times L', \omega = uv\}$
- On définit récursivement sur $\mathbb{N}$ la puissance n-ième de L par :
  - $L^0 = \{\varepsilon\}$
  - $\forall n \in \mathbb{N}, L^{n+1} = LL^n$
- La **fermeture de Kleene** de L, aussi appelée l'étoile de L : $L^* = \bigcup_{n \in \mathbb{N}} L^n$

  L esst commposé des mots sur Σ qui sont la concaténation d'un nombre arbitraire de mots de L

Exemple 5: Avec L = {a, ab, bb} et G = {ε, a, ba}

LG = {a, ab, bb, aa, aba, bba, abba, bbba}
L^2 = {aa, aab, abb, aba, abab, abbb, bba, bbab, bbbb}
$\{u^2, u \in L\}$ = {aa, abab, bbbb}

Avertissement

$L^n \neq \{u^n \mid u \in L\}$

🔥 ***Remarque***

$\varepsilon \in L^*$ pour tout L car $L^0 = \{\varepsilon\}$
En particulier, $\emptyset^* = \{\varepsilon\}$

Notation

Si L est un langage, on note $L^+ = \bigcup_{n \in \mathbb{N}} L^n$

⚠️ **Avertissement**

L^+ n'est pas toujours égal à $L^* \setminus \{\varepsilon\}$, en effet si $\varepsilon \in L$, alors $\varepsilon \in L^+$

II.3 Langages et expressions rationnelles (= régulières)

Définition

L'ensemble des **expressions régulières** sur un alphabet Σ est défini inductivement par :

- $\emptyset$ est une expression régulière
- ε est une expression régulière
- $\forall a \in \Sigma, a$ est une expression régulière
- Si e_1, e_2 sont des epxressions régulières, alors :
  - $(e_1 e_2)$ est une expression régulière
  - $(e_1 + e_2)$ est une expression régulière
  - e_1^* est une expression régulière

Exemple 6: Sur $\Sigma = \{a, b\}, E = (((ab) + a)^* b)$ est une expression régulière

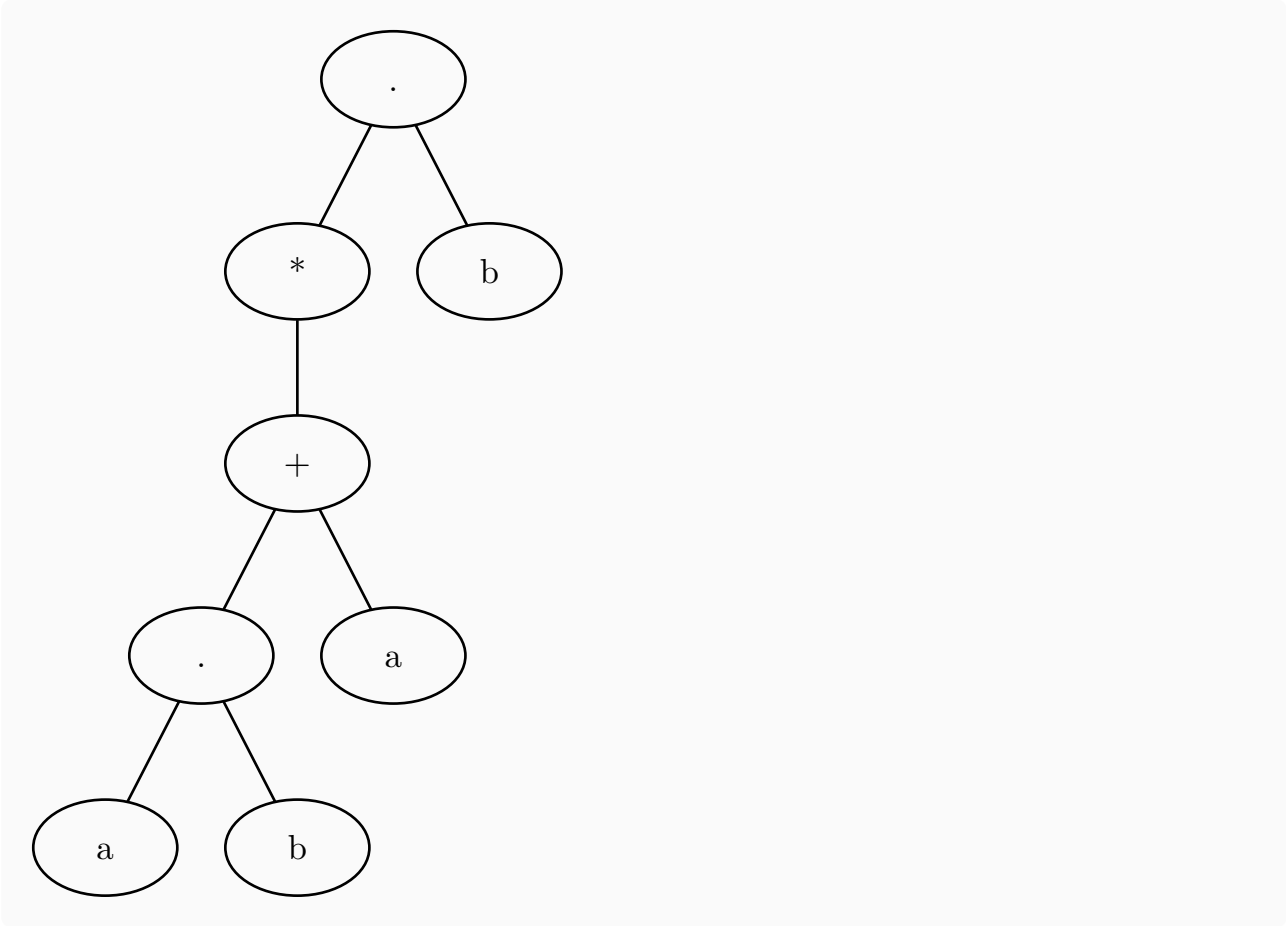

🔥 ***Remarque***

On n'écrit jamais toutes les parenthèses car on utilise les règle de priorité suivante : $\star > \cdot > +$

Dans l'exemple précédent, E s'écrirait plutôt (ab + a)*b

Définition

On définit le langage $\mathcal{L}(e)$ associé à une expression régulière e inductivement :

- $\mathcal{L}(\emptyset) = \emptyset$
- $\mathcal{L}(\varepsilon) = \{\varepsilon\}$
- $\forall a \in \Sigma, \mathcal{L}(a) = \{a\}$
- Si e_1 et e_2 sont des expressions régulières
  - $\mathcal{L}(e_1 e_2) = \mathcal{L}(e_1)\mathcal{L}(e_2)$
  - $\mathcal{L}(e_1 + e_2) = \mathcal{L}(e_1) + \mathcal{L}(e_2)$
  - $\mathcal{L}(e_1^\star) = \mathcal{L}(e_1)^\star$

On dit aussi que $\mathcal{L}(e)$ est le **langage dénoté** par e

Définition

Un langage L sur Σ est **rationnel** si et seulement si il existe e une epression réuglière telle que $L = \mathcal{L}(e)$

On note $\mathrm{Rat}(\Sigma^\star)$ l'ensemble de tous les langages rationnels

Remarque

Un même langage rationnel peut être dénoté par plusieurs expressions rationnelles

Par exemple sur $\Sigma = \{a, b\}$, $a + \emptyset, \varepsilon a, a + a + \emptyset$ sont des expressions rationnelles différentens mais dénotent toutes $\{a\}$, on dit qu'elles sont **équivalentes**«

Exemple 7:

1. Tous les langages finis sont rationnels

   Chaque mot d'un langage fini est la concaténation de ses lettres, donc si $u = u_1 ... u_n$, alors $u_1 ... u_n$ est une expression rationnelle pour $\{u\}$. Comme le langage est fini, il suffit de faire l'union des expressions rationnelles dénotant chacun de ses mots

2. Σ^* est rationnel car il est dénoté par $(a_1 + ... + a_k)$ avec $\Sigma = \{a_1, ..., a_k\}$
3. Si $m \in \Sigma^*$, l'ensemble des mots qui contiennent m est rationnel car il est dénoté par $\Sigma^* m \Sigma^*$
4. Sur $\Sigma = \{a, b\}$, le langage dénoté par $a^* b^*$ est rationnel

   Avertissement

   Pour le dernier exemple, il serait abusif de dire que le langage $a^* b^*$ est rationnel, car il ne s'agit pas d'un langage mais d'une expression rationnelle, et seul les langages sont rationnels.

   On s'autorisera cependant rapidement à faire cet abus.

5. $(a + ba)^*$ est rationnel, c'est l'ensemble des mots tel que chaque b est suivi d'un a
6. $(a^* b)^*$ est rationnel, c'est ε et tous les mots qui finissent par b, une autre expression rationnelle pour ce langage est $(a + b)^* b + \varepsilon$

Théorème (1): Il existe des langages non rationnels

Démonstation: $\mathcal{P}(\Sigma^*)$ est indénombrable alors que $\mathrm{Rat}(\Sigma^*)$ est dénombrable, car il y a plus d'expressions régulières sur Σ que de langages rationnels et l'ensemble des expressions régulières sur Σ est dénombrable.

En effet, l'ensemble des expressions régulières sur Σ est inclus dans Γ^* où $\Gamma = \Sigma \cup \{(,),+,\cdot,^*,\varepsilon,\emptyset\}$, qui est dénombrable

🔥 ***Remarque***

Cette preuve n'exhibe pas de langage non rationnel mais en voici deux :
- $\{a^n b^n \mid n \in \mathbb{N}\}$
- Le langage de Dyck

III Langages locaux

III.1 Définitions

Proposition 6: Si L est un langage sur Σ, on note :

- P(L) $= \{a \in \Sigma \mid a\Sigma^* \cap L \neq \emptyset\}$
  L'ensemble des lettres de Σ qui sont la première lettre d'un mot de L
- D(L) $= \{a \in \Sigma \mid \Sigma^* a \cap L \neq \emptyset\}$
- F(L) $= \{m \in \Sigma^2 \mid \Sigma^* m \Sigma^* \cap L \neq \emptyset\}$
  L'ensemble des facteurs de taille 2 de mots de L
- N(L) $= \Sigma^2 \setminus F(L)$

Alors, $L\{\varepsilon\} \subset$ loc(L) où loc(L) $= (P(L)\Sigma^* \cap \Sigma^* D(L)) \setminus (\Sigma^* N(L) \Sigma^*)$

Démonstation: Soit $m \in L\{\varepsilon\}$
Comme $m \neq \varepsilon$, il a une première lettre qui appartient à P(L), donc $m \in P(L)\Sigma^*$

m a aussi une dernière lettre qui appartient à D(L), donc $m \in \Sigma^* D(L)$

Supposons par l'absurde que $m \in \Sigma^* N(L) \Sigma^*$
Alors $m = ufv$ et donc f serait dans F(L) $= \Sigma^* \setminus N(L)$, ce qui seraot absurde
Ainsi, $m \notin \Sigma^* N(L) \Sigma^*$ et finalement, $m \in$ loc(L)

ℹ **Définition**

Un langage est dit **local** si l'incusion $L \setminus \{\varepsilon\} =$ loc(L) est une égalité

Exemple 8: Sur $\Sigma = \{a, b\}$

- L $= a^\star$ est local car
  - P(L) = {a}
  - D(L) = {a}
  - F(L) = {aa}
  - N(L) = {ab, ba, bb}

  et la localité est immédiate

- L $= (ab)^\star$ est local

  - On calcule P(L), D(L), F(L), N(L)
  - On montre que loc(L) $\subset$ L$\backslash\{\varepsilon\}$

- L $= (ab)^\star + a^\star$ n'est pas local

  - P(L) = {a}
  - D(L) = {a, b}
  - F(L) = {ab, ba, aa}
  - N(L) = {bb}

  Or, aab $\in$ (P(L)$\Sigma^\star \cap \Sigma^\star$D(L)) $\setminus$ ($\Sigma^\star$N(L)$\Sigma^\star$), mais aab $\notin ((ab)^\star + a^\star) \setminus \{\varepsilon\}$

III.2 Stabilité des langages locaux

Proposition 7:
Si L_1 et L_2 sont deux langages locaux, respectivement sur Σ_1 et Σ_2, et $\Sigma_1 \cap \Sigma_2 = \emptyset$

Alors $L_1 + L_2$ et $L_1 L_2$ sont des langages locaux

🔥 ***Remarque***

L'hypothèse $\Sigma_1 \cap \Sigma_2 = \emptyset$ est essentielle, si ce n'est pas le cas, on trouve dans l'exemple précédent un contre exemple

Démonstation:

- Pour l'union

  Il suffit de montrer que loc$(L_1 + L_2) \subset (L_1 + L_2) \setminus \{\varepsilon\}$

  Soit $u = u_1 ... u_k \in$ loc$(L_1 + L_2)$, alors par définition,
  $u_1 \in$ P$(L_1 + L_2) = P(L_1) + P(L_2)$
  Sans perte de généralité, on peut supposer $u_1 \in$ P(L_1)

Or,

$$\begin{cases} u_1u_2 \in \mathrm{F}(L_1 + L_2) = \mathrm{F}(L_1) + \mathrm{F}(L_2) \\ u_1 \in P(L_1), \text{ donc } u_1 \in \Sigma_1 \end{cases}$$

Ceci implique que $u_1u_2 \in F(L_1)$, car les alphabets sont disjoints.
De même, en procédant facteur par facteur, $u_2u_3, ..., u_{k-1}u_k \in \mathrm{F}(L_1)$

$u_k \in \mathrm{D}(L_1 + L_2) = \mathrm{D}(L_1) + \mathrm{D}(L_2)$ et $u_k \in \mathrm{F}(L_1)$.
Par conséquent, par disjonction des alphabets, $u_k \in \mathrm{D}(L_1)$

Ainsi, $u \in (\mathrm{P}(L_1)\Sigma^\star \cap \Sigma^\star\ \mathrm{D}(L_1)) \setminus \Sigma^\star \mathrm{N}(L_1)\Sigma^\star = \mathrm{loc}(L_1) = L_1\{\varepsilon\}$ par localité de L_1

- Pour la concaténation, on veut montrer que $\mathrm{loc}(L_1L_2) \in L_1L_2 \setminus \{\varepsilon\}$
  Soit $u = u_1...u_k \in \mathrm{loc}(L_1L_2)$

> **Interlude : Rappels du TP1**
>
> $$P(L_1L_2) = \begin{cases} P(L_1) \text{ si } \varepsilon \notin L_1 \\ P(L_1) + P(L_2) \text{ si } \ \varepsilon \in L_1 \end{cases}$$
>
> $$D(L_1L_2) = \begin{cases} D(L_2) \text{ si } \ \varepsilon \notin L_2 \\ D(L_1) + D(L_2) \text{ si } \ \varepsilon \in L_2 \end{cases}$$
>
> $$F(L_1L_2) = F(L_1) + F(L_2) + D(L_1)P(L_1)$$

On sait que $u_1 \in P(L_1L_2)$

- Si $u_1 \in \Sigma_2$, alors $u_1 \in P(L_2)$ et $\varepsilon \in L_1$

  De plus, $u_1u_2 \in F(L_2)$ par disjonction des alphabets

  Puis, avec le même raisonnement que précédemment, $u_2u_3, ..., u_{k+1}u_k \in F(L_2)$.
  Ainsi, $u_k \in \Sigma_2$, donc $u_k \in D(L_2)$ et $u_k \in D(L_1L_2)$

  Comme précédemment $u \in \mathrm{loc}(L_2) = L_2 \setminus \{\varepsilon\}$ car L_2 est local.

  Ainsi, $u = \varepsilon u \in L_1L_2$

- Si $u_1 \in \Sigma_1$

  On considère alors $u_1..u_p$ le plus grand préfixe de u qui est dans $\Sigma_1^\star$

  - Si $p = k$, le plus grand préfixe de u dans $\Sigma_1^\star$ est u.
    Alors comme précedemment, on montre que $u_1u_2, ...u_{k-1}u_k \in \mathrm{F}(L_1)$ et que $u_k \in \mathrm{D}(L_1)$

    Par conséquent, $u_k \in \mathrm{loc}(L_1) = L_1 \setminus \{\varepsilon\}$ car L_1 est local, et $\varepsilon \in L_2$
    Et alors, $u\varepsilon \in L_1L_2$

– Si $p < k$, on peut alors adapter la preuve précédente.

Proposition 8: La fermeture de Kleene d'un langage local est locale

Démonstation: Soit L un langage local, on sait que
- $P(L^\star) = P(L)$
- $D(L^\star) = D(L)$
- $F(L^\star) = F(L) + D(L)P(L)$

Soit $u \in \text{loc}(L^\star)$

On sait que les facteurs de taille 2 de u sont soit dans $F(L)$, soit dans $D(L)P(L)$. On découpe u à chaque fois qu'on rencontre un facteur de taille 2 dans $D(L)P(L)$. Alors, chaque morceau est dans $\text{loc}(L)$, et est donc dans $L \setminus \{\varepsilon\}$ par localité de L. Ce qui donne donc immédiatement que $u \in L^\star \setminus \{€\varepsilon\}$, et donc $\text{loc}(L^\star) \subset L^\star \setminus \{\varepsilon\}$

Ainsi, $L^\star$ est local.

III.3 Expressions rationnelles linéraires

🔥 ***Remarque***

Il existe des langages rationnels non locaux, par exmeple celui dénoté par $(ab)^\star + a^\star$. Le but de cette partie est de présenter un sous-ensemble de langages rationnels dont tous les éléments sont locaux

ℹ **Définition**

Une expression rationnelle e sur Σ est dite linéaire si chaque lettre n'y apparaît qu'au plus une seule fois. Dit autrement, si $\forall a \in \Sigma, |e|_a \leq 1$

Proposition 9: Toute expression rationnelle linéaire dénote un langage local

Démonstation: On montre par induction structurelle sur l'expression rationnelles e la propriété $P(e)$: e linéaire $\Rightarrow L(e)$ local

- $\emptyset$ dénote $\emptyset$ qui est local
- ε dénote $\{\varepsilon\}$ qui est local
- Soit $a \in \Sigma$, a dénote $\{a\}$ qui est local
- Si $e = e_1 + e_2$ avec e_1 et e_2 des expressions rationnelles et e linéaire.
  Alors par $P(e_1)$ et $P(e_2)$, $L(e_1)$ et $L(e_2)$ sont locaux.

Or, $L(e) = L(e_1) + L(e_2)$ et les alphabets de e_1 et e_2 sont disjoints par linéarité de e, et donc par le résultat précédent, $L(e)$ est local

- Si $e = e_1 e_2$, avec e linéaire, on applique le même raisonnement
- Si $e = f^\star$ est linéaire, alors f est linéaire et donc $L(f)$ est locale par $L(F)$.

  Or, $L(e) = L(f^\star) = L(f)^\star$,, qui est local par stabilité des langages locaux par fermeture de Kleene

🔥 ***Remarque***

Les récipriques sont fausses Par exemple, $aa^\star$ dénote un langage local pour lequel aucune expression rationnelle n'est linéaire.