Chapitre 6 :
Grammaires non contextuelles

Table des matières

N.1 Introduction 2

I Grammaires non contextuelles 3

I.1 Définitions 3

I.2 Dérivations 4

I.3 Langages algébriques 5

I.4 Langages algébriques et langages rationnels 8

II Arbres syntaxiques 9

II.1 Défintion 9

II.2 Grammaires ambigues 11

III Formes normales et stabilités de Alg(Σ^*) 14

III.1 Grammaires réduites 14

III.2 Grammaires propres 16

III.3 Stabilité de Alg(Σ^*) 18

N.1 Introduction

Les langages rationnels sont utiles pour détecter les motifs présents (par exemple dans un code source), mais pas pour en déduire la structure de ce qui est lu.

Un autre problème des langages rationnels : ils ne capturent pas certains langages importants comme le langage de Dyck

Objectifs

- Découvrir une classe de langages plus expressive que les langages rationnels.
- Découvrir un nouveau formalisme de construction de langage.
- Effleurer les concepts d'analyse lexicale et syntaxique.

Point Culture : La hiérarchie de Chomsky

Dispotisif de construction = Grammaire	Classe de langage	Dispositif de reconnaissance = Machine
Grammaires de type 0	Langages récurisvement énumérables	Machines de Turing
Grammaires de type 1 = Grammaires contextuelles	Langages contextuels	Automates linéairements bornés
Grammaires de type 2 = Grammaires non contextuelles	Langages algébriques	Automates à pile
Grammaires de type 3 = Grammaires régulères	Langages rationnels	Automates finis

I Grammaires non contextuelles

I.1 Définitions

Définition

Une **grammaire non contextuelle** ou **hors contexte / algébrique** est un quadruplet $G = (\Sigma, V, S, \mathcal{R})$ avec

- Σ est un alphabet, dont les symboles sont dits « **(symboles) terminaux** »
- V est un alphabet dont les symboles sont dits « **variables** » ou **non-terminaux**.
- $\Sigma \cap V = \emptyset$
- $S \in V$ est l'« **axiome** » de G
- $\mathcal{R}$ est une partie finie de $V \times (V \cup \Sigma)^*$, chaque élément de $\mathcal{R}$ est une **règle de production**

Exemple 1:

$G = (\{a, b\}, \{S\}, S, \{(S, \varepsilon), (S, aSb)\})$ est une grammaire

Conventions

- À la place d'écrire (X, m) pour décrire une règle, on écrit $X \to m$, où ($\to$ se lit « sse réécrit en »)
- Si $X \to m_1$ et $X \to m_2$ sont des règles, on écrit plutôt $X \to m_1 \mid m_2$
- Souvent, on écrira les terminaux avec des lettres minuscules et les non-terminaux avec des lettres majuscules.

Ainsi, on peut présenter G de la manière suivante :
G est la grammaires dont les règles sont : $S \to \varepsilon \mid aSb$

Remarque

G engendre $\{a^n b^n \mid n \in \mathbb{N}\}$

Point Culture : Pourquoi « hors contexte » ?

Dans les grammaires non-contextuelles, on remplace un non-terminal indépendament du contexte et des symboles extérieurs. Dans une grammaire contextuelle, on pourrait avoir des règles comme : $aX \to aY$ et $bX \to bZ$ ou bien $XY \to ab \mid z$ et $aX \to Yb$

I.2 Dérivations

Définition

Soit $G = (\Sigma, V, S, \mathcal{R})$ une grammaire non-contextuelle et $u \in (\Sigma \cup V)^*$.
On dit que :

- u se **dérive immédiatement** en v dans G s'il existe une règle $X \to m$ telle que $u = u_1 X u_2$ et $v = u_1 m u_2$
  On le note $u \Rightarrow v$
- Si $u_1 \in \Sigma^*$, on dit que la dérivation est immédiate à gauche
- Si $u_2 \in \Sigma^*$, on dit que la dérivation est immédiate à droite
  Notées $u \underset{g}{\Rightarrow} v$ et $u \underset{d}{\Rightarrow} v$

Remarque

Une dérivation peut n'être ni gauche ni droite.

Exemple 2: Avec G_D telle que

$$\begin{cases} S \to TS \mid \varepsilon \\ T \to aSb \end{cases}$$

TSaSbT se dérive immédiatement à gauche en aSbSaSbT
TSaSbT se dérive immédiatement en TSabT

Définition

Soit $G = (\Sigma, V, S, \mathcal{R})$ une grammaire non-contextuelle et $u \in (\Sigma \cup V)^*$.
On dit que u se dérive en v s'il existe une suite de dérivations immédiates (potentiellement vide) $(u_i \Rightarrow v_i)_{i \in [\![0,k]\!]}$ tel que $u_0 = u$ et $v_k = v$ et $u_{i+1} = v_i$.

On note $u \overset{*}{\Rightarrow} v$.

On note $u \overset{k}{\Rightarrow} v$ si la dérivation permettant de passer de u à v fait k étapes.

Remarque

- Pour tout mot u, $u \overset{*}{\Rightarrow} u$
- Si toutes les dérivations immédiates étaient gauche on dit que la dérivation est gauche, idem pour droite.

Exemple 3: Dans G_D, $S \overset{*}{\Rightarrow} abaabb$
En effet,
$S \Rightarrow T\ \underline{S} \Rightarrow \underline{T}\ ST \Rightarrow a\ \underline{S}\ bTS \Rightarrow ab\ \underline{T}\ S \Rightarrow aba\ \underline{S}\ bS \Rightarrow aba\ \underline{T}\ SbS \Rightarrow$
$abaa\ \underline{S}\ b\ \underline{S}\ b\ \underline{S} \Rightarrow abaabb$

🔥 ***Remarque***

Si $u \overset{*}{\Rightarrow} v$, il n'y a pas unicité de la dérivation

🔥 ***Remarque***

Dans le programme, la dérivation se note $\Rightarrow$ et $\overset{*}{\Rightarrow}$ mais on retrouve aussi parfois $\rightarrow$ et $\overset{*}{\rightarrow}$

I.3 Langages algébriques

i **Définition**

Le **langage engendré** par une grammaire $G = (\Sigma, V, S, \mathcal{R})$ est
$\mathcal{L}(G) = \left\{m \in \Sigma^* \mid S \overset{*}{\Rightarrow} m\right\}$

Exemple 4: G_D engendre le langage de Dyck à une parenthèse
$\mathcal{D} = \{\varepsilon\} \cup \{m \in \{a,b\}^* \mid \exists (u,v) \in \mathcal{D}^2, m = aubv\}$

Par double inclusion

- $\mathcal{D} \subset \mathcal{L}(G_D)$

  Montrons par récurrence forte sur $n \in \mathbb{N}$, $\mathcal{H}_n$: tout mot de $\mathcal{D}$ de longueur n est dans $\mathcal{L}(G_D)$.

  - Le seul mot de longeur 0 dans $\mathcal{D}$ est ε. Or, $S \Rightarrow \varepsilon$ dans G_D donc $\varepsilon \in \mathcal{L}(G_D)$
  - Soit $n \in \mathbb{N}$ tel que $\forall k \leq n, \mathcal{H}_k$. Soit $m \in \mathcal{D}$ de longueur $n+1$.
    Alors il existe $(u,v) \in \mathcal{D}^2$ tel que $m = aubv$ avec u et v de taille $< n$ donc on peut leur appliquer l'hypothèse de récurrence. Ainsi, $S \overset{*}{\Rightarrow} u$ et $S \overset{*}{\Rightarrow} v$
    Ainsi, $S \Rightarrow TS \Rightarrow aSbS \overset{*}{\Rightarrow} aubv = m$
    Donc $m \in \mathcal{L}(G_D)$

- $\mathcal{L}(G_D) \subset \mathcal{D}$

  Montrons par récurrrence forte sur $n \in \mathbb{N}^*$, $\mathcal{H}_n$: pour tout $m \in \{a,b\}^*$, si $S \overset{n}{\Rightarrow} m$ alors $m \in \mathcal{D}$

  - Pour $n = 1$, le seul mot engendrable est ε et $\varepsilon \in \mathcal{D}$

- Soit $n \in \mathbb{N}^*$ tel que $\forall k \leq n, \mathcal{H}_k$. Soit $m \in \{a,b\}^*$ tel que $S \overset{n+1}{\Rightarrow} m$
  Comme $n+1 \geq 2$, la première dérivation immédiate est $S \Rightarrow TS$. On peut supposer que la dérivation immédiate suivante est $TS \Rightarrow aSbS$ car T doit être éliminé et la grammaire est hors-contexte.
  Ainsi, $S \Rightarrow TS \Rightarrow aSbS \overset{n-1}{\Rightarrow} m$. Ainsi, il existe $(u,v) \in \{a,b\}^*$ et $n_1, n_2 \in \mathbb{N}$ tel que

$$\begin{cases} m = aubv \\ S \overset{n_1}{\Rightarrow} u \\ S \overset{n_2}{\Rightarrow} u \\ n_1 + n_2 = n-1 \end{cases}$$

  Comme $n_1 < n$ et $S \overset{n_1}{\Rightarrow} u, u \in \mathcal{L}(G_D)$ donc $u \in \mathcal{D}$
  Comme $n_2 < n$ et $S \overset{n_2}{\Rightarrow} u, u \in \mathcal{L}(G_D)$ donc $u \in \mathcal{D}$

  Ainsi, $m \in \mathcal{D}$

Méthode

Pour montrer que la langage engendré par une grammaire connue G est le langage L, on montre :
- $\mathcal{L}(G) \subset L$ se montre par récurrence forte sur la longueur dérivations dans G.
- $L \subset \mathcal{L}(G)$ se montre par récurrence forte sur la longueur des mots de L.

Exemple 5: G tel que $S \to aSb \mid \varepsilon$ engendre $\{a^n b^n \mid n \in \mathbb{N}\}$

- Montrons par récurrence forte sur $n \in \mathbb{N}^*$,
  $\mathcal{H}_n$: tout mot $u \in \{a,b\}^*$ tel que $S \overset{n}{\Rightarrow} u$ est dans L

  La seule dérivation de longueur 1 dans G est $S \Rightarrow \varepsilon$ et $\varepsilon \in L$.

  Soit $n \in \mathbb{N}^*$ tel que $\forall k \leq n, \mathcal{H}_k$ et soit $u \in \{a,b\}^*$ tel que $S \overset{n+1}{\Rightarrow} u$.
  Cette dérivation commmence par $S \Rightarrow aSb$ sinon elle serait trop courte.
  Ainsi, $S \Rightarrow aSb \overset{n}{\Rightarrow} u$. Donc il existe $n \in \{a,b\}^*$ tel que $S \overset{n}{\Rightarrow} v$ et $u = avb$.
  En appliquant l'hypothèse de récurrence à v, $v \in L$ donc il existe $i \in \mathbb{N}$ tel que $v = a^i b^i$.
  Ainsi $u = a^{i+1} b^{i+1} \in L$

- Montrons par récurrence forte sur $n \in \mathbb{N}$,
  $\mathcal{H}_k$: tout mot de L de longueur n est engendré par G.

  Le seul mot de longueur 0 dans L est ε. Or $S \Rightarrow \varepsilon$ dans G donc $\varepsilon \in \mathcal{L}(G)$.

Soit $n \in \mathbb{N}$ tel que $\forall k \leq n, \mathcal{H}_k$ et soit $u \in L$ de longueur $n+1$.
$u \in L$ donc $n+1$ est pair.
Ainsi, il existe $i \in \mathbb{N}^*$ tel que $u = a^i b^i = aa^{i-1}b^{i-1}b$ avec $a^{i-1}b^{i-1} \in L$ car $i \neq 0$ et ce mot est longueur $< n+1$.
On applique l'hypothèse de récurrence sur ce mot : il existe une dérivation $S \overset{*}{\Rightarrow} a^{i-1}b^{i-1}$.
Alors $S \Rightarrow aSb \overset{*}{\Rightarrow} aa^{i-1}b^{i-1}b = u$ est une dérivation dans G et donc $u \in \mathcal{L}(G)$.

Exemple 6:

- Le langage engendré par $S \to aS \mid b$ est dénoté par a^*b
- Le langage engendré par

$$\begin{cases} S \to TS \mid \varepsilon \\ T \to a_1 S \overline{a_1} \mid a_2 S \overline{a_2} \mid \ldots \mid a_n S \overline{a_n} \end{cases}$$

  sur $\{a_1, \overline{a_1}, \ldots, a_n, \overline{a_n}\}$ est le langage de Dyck à n couples de parenthèses.
- le langage engendré par $S \to ST \mid \varepsilon$, $T \to aSb$ est le langage de Dyck à une parenthèse.

🔥 ***Remarque***

Un même langage peut être engrendré par deux grammaires différentes. on dit que ces grammaires sont <u>faiblement équivalentes</u>.

Exemple 7: On consiède la grammaire G_C
dont les terminaux sont $\{x, y, 0, 1, \ldots, 9, ==, \text{if}, \text{else}, (,), ;, =, <, >, \}$
dont les non-terminaux sont {I, E, T, V, N, C}
dont l'axiome est I
dont les règle sont :
I $\to$ if (T) I | if (T) I else I | E;
E $\to$ V = N
V $\to$ x | y
N $\to$ CN | C
T $\to$ V < N | V > N | V == N

Par exemple, if $(x < 36)$ $y = 7$; est engendré par G_C.

I.4 Langages algébriques et langages rationnels

Définition

L'ensemble des **langages algébriques** sur Σ, noté $\mathrm{Alg}(\Sigma^*)$ est l'ensemble des langages engendrés pas une grammaire algébrique.

Proposition 1: $\mathrm{Alg}(\Sigma^*) \neq \mathscr{P}(\Sigma^*)$

Démonstation:
$\mathscr{P}(\Sigma^*)$ est indénombrable
$\mathrm{Alg}(\Sigma^*)$ est dénombrable car il y a moins de langages algébriques que de grammaires sur Σ. Or, l'ensemble des grammaires est l'union sur $n \in \mathbb{N}$ de l'ensemble des grammaires décrites par n caractères, qui est fini.

Point Culture

$\{a^n b^n c^n \mid n \in \mathbb{N}\}$ n'est pas algébrique.

Proposition 2: $\mathrm{Rat}(\Sigma^*) \subsetneq \mathrm{Alg}(\Sigma^*)$

Démonstation:
Si on a l'inclusion, elle est stricte car $\{a^n b^n \mid n \in \mathbb{N}\} \in \mathrm{Alg}(\{a,b\}^*) \setminus \mathrm{Rat}(\{a,b\}^*)$

Soit $L \in \mathrm{Rat}(\Sigma^*)$. Par le théorème de Kleene, il existe $A = (\Sigma, Q, q_0, F, \delta)$ un ADC qui reconnaît L.

Considérons alors $G_L = \left\{\Sigma, V, X_{q_0}, \mathcal{R}\right\}$ avec :
- $V = \left\{X_q \mid q \in Q\right\}$ qui est bien un alphabet car Q est fini.
- $\mathcal{R} = \left\{X_q \to aX_{\delta(q,a)} \mid q \in Q, a \in \Sigma\right\} \cup \left\{X_q \to \varepsilon \mid q \in F\right\}$

G_L engendre le langage L.

<u>Étape 1 :</u> Montrons par récurrence sur $n \in \mathbb{N}$:
$\mathcal{H}_n$: Pour tout mot u de longueur n, et pour tout $q, q' \in Q$, $X_q \overset{*}{\Rightarrow} uXq'$ si et seulement si $\delta^*(q,u) = q'$

Laissé en exercice au lecteur

<u>Étape 2 :</u> Montrons que $L = \mathcal{L}(G_L)$ par double inclusion

Si $u \in L$, il existe $q_f \in F$ tel que $\delta^*(q_0, u) = q_f$.
Il existe alors une dérivation $X_{q_0} \overset{*}{\Rightarrow} uX_{q_f}$.
En appliquant $X_{q_f} \to \varepsilon$, on a $X_{q_0} \overset{*}{\Rightarrow} u$ donc $u \in \mathcal{L}(G_L)$.

Si $u \in \mathcal{L}(G_L)$, il existe une dérivation $X_{q_0} \overset{*}{\Rightarrow} u$
Comme u ne contient plus de variable et vu la forme des règles de G
cette dérivation se décompose en $X_{q_0} \overset{*}{\Rightarrow} uX_{q_f} \Rightarrow u$.
Alors $\delta^*(q_0, u) = q_f \in F$, donc u est reconnu par A et $u \in L$.

II Arbres syntaxiques

II.1 Défintion

Définition

Soit $G = (\Sigma, V, S, \mathcal{R})$ uen grammaire

Un **arbre de dérivation** dans G est un arbre dont les noeuds sont des étiquettés par des éléments de $V \cup \Sigma \cup \{\varepsilon\}$ tel que :

- La racine est étiquettée par S
- Les feuilles sont étiquettées par des éléments de $\Sigma \cup \varepsilon$
- Les noeuds internes sont étiquettés par des éléments de V
- Si $u_1, ..., u_n$ sont les étiquettes des fils du noeud étiquetté par $X \in V$ alors $X \to u_1....u_n \in \mathcal{R}$

Remarque

On dit aussi **arbre syntaxique** ou **arbre d'analyse**

Définition

Si u est le mot obtenu en concaténant les feuilles les feuilles d'un arbre syntaxique A de gauche à droite, on dit que A est <u>un</u> **arbre syntaxique pour u**

Exemple 8: Avec G_D voici un arbre syntaxique pour ab.

$S \Rightarrow TS \Rightarrow ASbS \Rightarrow abS \Rightarrow ab$
$S \Rightarrow TS \Rightarrow T \Rightarrow aSb \Rightarrow ab$

Ces deux dérivations différentes ont le même arbre syntaxique, ce qui montre qu'elles ont la même structure.

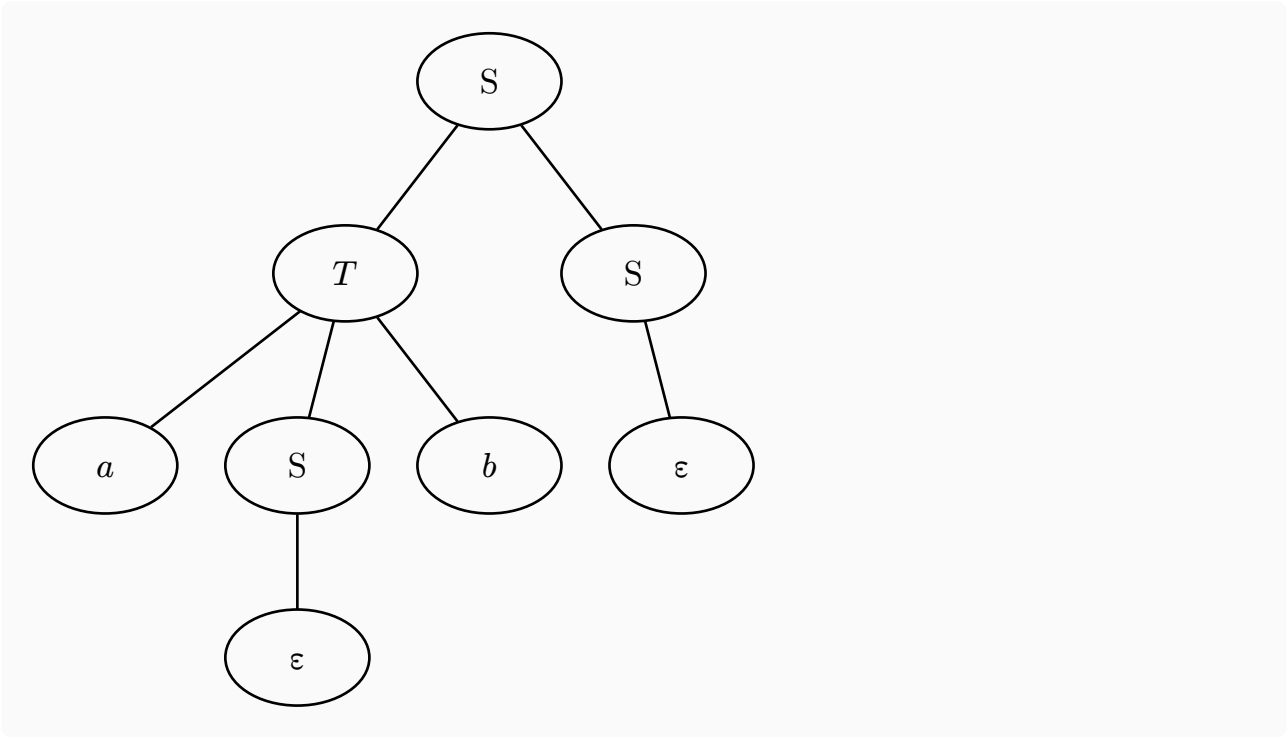

🔥 ***Remarque***

Deux dérivations différentes peuvent correspondre au même arbre syntaxique

⚠️ **Avertissement**

Parfois, on peut avoir des mots qui ont plusieurs arbres syntaxiques vraiment différent

Exemple 9: $S \to S + S \mid S \times S \mid 2$ sur $\{2, +, \times\}$
Observons le mot $2 + 2 \times 2$, il a deux arbres syntaxiques différents :

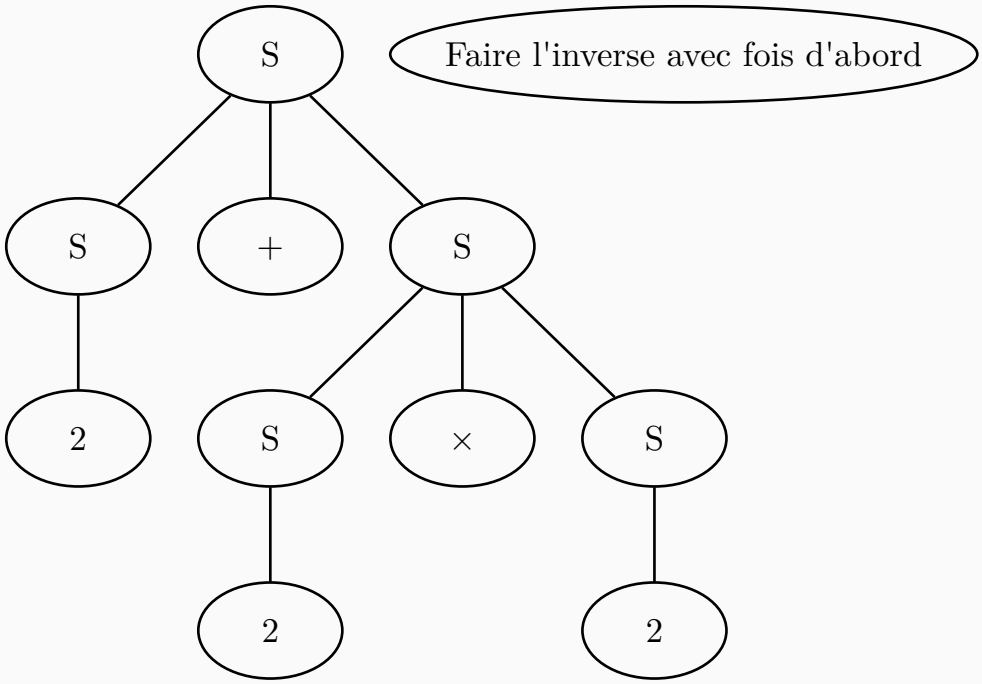

$2 + (2 \times 2) = 6$ mais $(2 + 2) \times 2 = 8$

II.2 Grammaires ambigues

Définition

Une grammaire G est dite <u>ambigue</u> s'il existe $u \in \mathcal{L}(G)$ qui admet deux arbres syntaxiques différents

Avertissement

Pour avoir ambiguité, il faut bien deux <u>arbres</u> différents, et pas deux dérivations différentes.

En revanche, l'existence de deux dérivation gauche (ou droite) différents est bien le signe que la grammaire est ambigue.

Exemple 10: La grammaire G_C est ambigue car
if $(x < 5)$ if $(x == 3)$ $y = 36$; else $y = 42$; admet deux abres syntaxiques différents

<u>Fait sur feuille, prend en photo et fait pas chier</u>

L'ambiguité vient du fait que le else peut être avec un if ou l'autre, on peut reparenthéser de deux manières:

```vim
if (x < 5){
  if (x == 3) y = 36;
  }
  else{
    y = 42;
  }
}

if (x < 5){
  if (x == 3) y 36;
  else y = 42;
}
```

Ce problème est **le problème du « dangling-else »**

<u>Solutions :</u>

- Utiliser du parenthésages
- Fixer des conventions de priorité, par exemple en C le else se rattache au if le plus proche
- Trouver une autre grammaire pour le langage qui ne soit pas ambigue

? Question

Peut-on éviter les grammaires ambigues ?

Exemple 11:
$S \to SS \mid a$ est ambigue. En effet, le mot aaa admet deux arbres syntaxiques différents (cf. Fig 1)

Cependant, $\mathcal{L}(G)$ est dénoté par a^+. Donc $G' : S \to aS \mid a$ engendre aussi a^+.
Or, cette grammaire n'est pas ambigue car tout mot qu'elle engendre l'est via une unique dérivation, donc admet un unique arbre syntaxique

i Définition

Un langage est dit **inhéremment ambigu** ou **intrinsèquement ambigu** si toute grammaire qui l'engendre est ambigue.

Ainsi, ici le langage dénoté par a^+ n'est pas intrinsèquement ambigu.

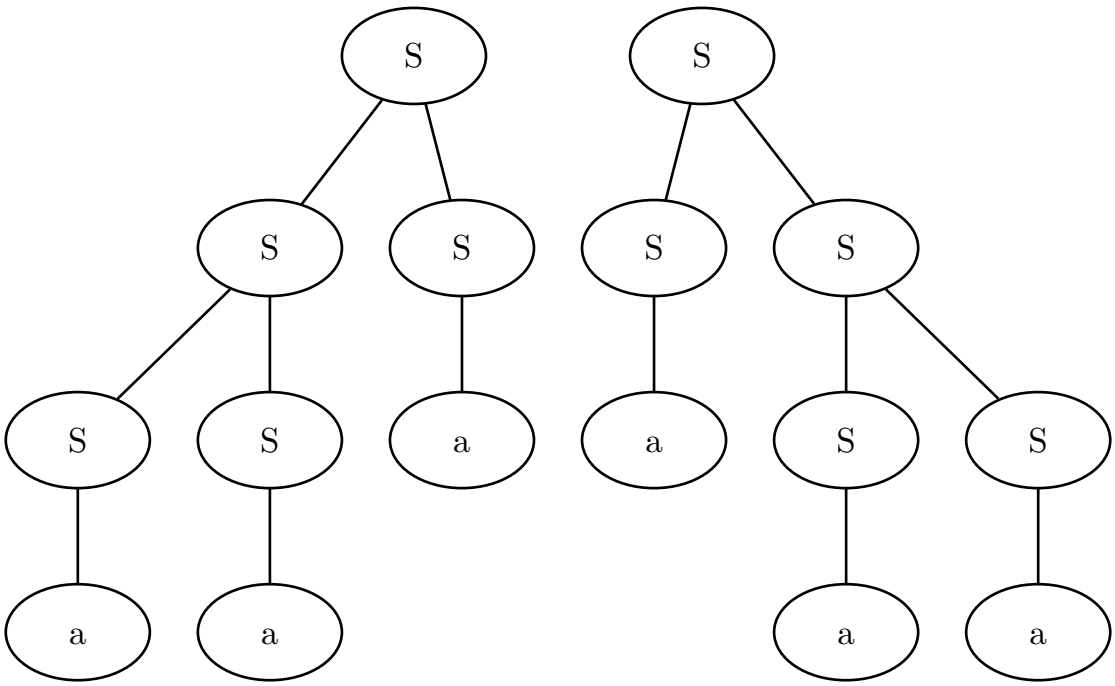

Fig. 1. – Deux arbres syntaxiques pour aaa

Point Culture

CG : $\{a^n b^n c^m \mid n, m \geq 0\} \cup \{a^n b^m c^m \mid n, m \geq 0\}$ est intrinsèquelement ambigu.

Question

Est-ce qu'on peut éviter les langages « très » ambigus ?

Définition

Le **degré d'ambiguité** d'une grammaire G est la borne supérieure du nombre d'arbres syntaxiques pour un même mot du langage.

Problème

Il existe des langages pour lesquels toute grammaire qui l'engendre a un degré d'ambiguité infini.

Théorème (1): Le problème :

$$\text{AMBIGUE} : \begin{cases} \underline{\text{Entrée :}} \text{ Une grammaire algébrique } G \\ \underline{\text{Question :}} \text{ Est-ce que } G \text{ est ambigue ?} \end{cases}$$

est indécidable

III Formes normales et stabilités de Alg(Σ^*)

III.1 Grammaires réduites

Définition

Si $G = (\Sigma, V, S, \mathcal{R})$ est une grammaire et $X \in V$,
on note $\mathcal{L}(G, X) = \left\{m \in \Sigma^* \mid X \overset{*}{\Rightarrow} m\right\}$

Remarque

$\mathcal{L}(G) = \mathcal{L}(G, S)$

Définition

Une grammaire G est dite **réduite** si :
1. Pour tout $X \in V$, $\mathcal{L}(G, X) \neq \emptyset$
2. Pour tout $X \in V$, $\exists (m_1, m_2) \in (\Sigma \cup V)^*$ tel que $S \overset{*}{\Rightarrow} m_1 X m_2$

Remarque

1. est l'analogue de la notion d'état co-accessible.
2. est l'analogue de la notion d'état accessible.

Réduite est l'analogue de la notion d'état émondé.

Vocabulaire

Une variable X qui vérifie 1. est un symbole productif.
Une variable X qui vérifie 2. est un symbole accessible.

Proposition 3: Pour toute grammaire G, il existe G' réduite telle que $\mathcal{L}(G) = \mathcal{L}(G')$

Démonstation: Voici un algorithme permettant de créer G' :

1. On calcule les symboles productifs récursivement de la façon suivante :
   $p_0 = \Sigma$ et $\forall n \geq 0, p_{n+1} = p_n \cup \{X \in V \mid X \to m, m \in p_n^*\}$

   $(p_n)_{n \in \mathbb{N}}$ stationne car elle croît et tous les p_n sont inclus dans $\Sigma \cup V$ qui est fini.
   Les symboles producteurs de G sont ceux de $p_\infty \cap V$, appelés P.

2. On supprime les symboles non-producteurs
3. On calcule les symboles accessibles récursivement de la façon suivante :
   $A_0 = \{S\}$ et $\forall n \geq 0$,
   $A_{n+1} = A_n \cup \{X \in V \mid \exists Y \in A_n, (m_1, m_2) \in (\Sigma \cup V)^*, Y \to m_1 X m_2 \in \mathcal{R}\}$

   Cette suite stationne en l'ensemble des smboles accessibles A de G.
4. $G' = (\Sigma, P \cap A, S, \mathcal{R}')$ avec $\mathcal{R}'$ est $\mathcal{R}$ dans lequel on enlève les règles qui font intervenir des variables qui ne sont pas dans $P' \cap A$. Et G' convient.

Exemple 12: $\Sigma = \{a, b\}$, $V = \{S, A, B, C\}$
$S \to aA \mid bAB \mid abAS \mid BC$
$A \to aB \mid bA \mid a$
$B \to aB \mid bB$
$C \to aA \mid bS \mid a$

$p_0 = \Sigma, p_1 = \{A, C\} \cup \Sigma$, $p_2 = \{A, C, S\} \cup \Sigma$, $p_3 = \{A, C, S\} \cup \Sigma$

On supprimes les symboles non producteur (B)
$S \to aA \mid abAS$
$A \to bA \mid a$
$C \to aA \mid bS \mid a$

$A_0 = \{S\}, A_1 = \{S, A\}, A_2 = \{S, A\}$
$S \to aA \mid abAS$
$A \to bA \mid a$

Avertissement

Attention à l'ordre de calcul : si on calcule les accessibles d'abord et les producteurs ensuite, la grammaire obtenue n'est pas forcément réduite.

$S \to a \mid S_1; S_1 \to S_1 S_2; S_2 \to b$
Ici toutes les variables sont accessible.
Les producteurs sont $\{S_2, S\}$.
Si on supprime S_1, on obtient $S \to a; S_2 \to b$ et ainsi S_2 n'est plus accessible.

Conséquence

On peut décider si $\mathcal{L}(G) = \emptyset$ quand G est une grammaire algébrique : il suffit de calculer l'ensemble des symboles producteurs et vérifier si S est dedans.
Cela peut se faire en $O(|V||\mathcal{R}|)$ où $|\mathcal{R}|$ est le nombre de symboles utilisés pour écrire les règles.

III.2 Grammaires propres

Définition

G est **propre** si elle ne contient aucune règle de la forme $X \to \varepsilon$ ou $X \to Y$ avec $(X, Y) \in V^2$

Proposition 4: Pour toute grammaire G, om existe une grammaire propre G' telle que $\mathcal{L}(G') = \mathcal{L}(G) \setminus \{\varepsilon\}$

Remarque

Si c'est vraiment important de conserver ε, on peut rajouter quelques règles à G' pour rattraper la génération

Démonstation:

1. On supprime les ε-productions (c'est à dire $X \to \varepsilon$)
   On ne peut pas juste les supprimer :
   si on supprime le ε dans $S \to aSb \mid \varepsilon$, on perd (tous) les mots du langage.

   On calcule récursivement :
   $E_0 = \{X \in V \mid X \to \varepsilon \in \mathcal{R}\}$
   $\forall n \in \mathbb{N}, E_{n+1} = E_n \cup \{X \in V \mid X \to m_1 ... m_k \in \mathcal{R}, m_1 \in E_n\}$

   $(E_n)_{n \in \mathbb{N}}$ stationne en $E = \left\{X \in V \mid X \overset{*}{\Rightarrow} \varepsilon\right\}$

   Pour toutes les règles $Y \to m_1 ... m_k$ on ajoute les règles $Y \to m'_1 ... m'_k$
   avec $m'_i = m_i$ si $m_i \notin E$, et $m'_i = m_i$ ou ε si $m_i \in E$.

   Puis on supprime les $X \to \varepsilon$

   Pour $S \to aSbS \mid \varepsilon$, S est ε-producteur et on obtient les règles :
   $S \to aSbS \mid abS \mid aSb \mid ab$

2. On supprime les règles de la forme $X \to Y$ avec $(X, Y) \in V$
   On ne peut toujours pas simplement les supprimer :
   $S \to X; X \to a$ donnerait $\emptyset$ au lieu de $S \to a$

   Pour cela, on calcule pour toute variable X l'ensemble
   $E(X) = \left\{Y \in V \mid Y \overset{*}{\Rightarrow} X\right\}$.
   $E(X)$ se calcule de la manière suviant :

   - On construit le graphe orienté dont les sommets sont les variables et tel que (X, Y) est un arc si et seulement si $X \to Y \in \mathcal{R}$.
   - On parcourt G^T à partir de X : les sommets atteints forment $E(X)$.

Ensuite, pour chaque variable X, pour chaque règle $X \to \alpha$ avec $\alpha \notin V$ et pour chaque $Y \in E(X)$, on ajoute la règle $Y \to \alpha$

Enfin, on supprime les règles de la forme $X \to Y$.

Conséquence

$$\text{MOT} : \begin{cases} \underline{\text{Entrée :}}\ G \text{ une grammaire algébrique sur } \Sigma\ ,\ m \in \Sigma^* \\ \underline{\text{Question :}}\ m \in \mathcal{L}(G)? \end{cases}$$

est décidable

Démonstation:

- Si $m = \varepsilon$, on calcule $E = \left\{X \in V \mid X \overset{*}{\Rightarrow} \varepsilon\right\}$.
  On cherche si $S \in E$
- Si $m \neq \varepsilon$, on proprifie G et on obtient une grammaire G' telle que $m \in \mathcal{L}(G)$ si et seulement si $m \in \mathcal{L}(G')$.

  Comme G' est propre, ses règles sont de la forme :
  - $X \to a \in \Sigma$
  - $X \to u$ avec $|u| \geq 0$

  Donc appliquer une règle dans G', soit produit un terminal, soit augmente strictement la taille du mot engendré.

  Ainsi, une dérivation de m dans G' ne peut pas avoir une longueur supérieure à $2 \times |m|$. Il y a donc un nombre fini de dérivations de longueur inférieur à $2 \times |m|$, il suffit alors de les construire toutes et regarder si l'une d'entre elle donne m.

Point Culture

Le problème MOT est dans P via l'algorithme de Cocke-Younger-Kasama (CYK).

Pour des grammaires avec des contraintes dessus, il y a des algorithmes d'analyses (LL, LR) qui permettent de faire ceci en temps polynomial « rapide ».

III.3 Stabilité de Alg(Σ^*)

Proposition 5: Alg(Σ^*) est stable par l'union, la concaténation et l'étoile.

Démonstation: Soient $L, L' \in \text{Alg}(\Sigma^*)$

Il existe $G = (\Sigma, V, S, \mathcal{R})$ et $G' = (\Sigma, V', S', \mathcal{R}')$
tels que $\mathcal{L}(G) = L, \mathcal{L}(G') = L'$

- $L \mid L' \in \text{Alg}(\Sigma^*)$ car il est engendré par
  $G'' = (\Sigma, V \cup V' \cup \{S_0\}, \mathcal{R} \cup \mathcal{R}' \cup \{S_0 \to S \mid S'\})$
- $LL' \in \text{Alg}(\Sigma^*)$ car il est engendré par
  $G'' = (\Sigma, V \cup V' \cup \{S_0\}, \mathcal{R} \cup \mathcal{R}' \cup \{S_0 \to SS'\})$
- $L^* \in \text{Alg}(\Sigma^*)$ car il est engendré par
  $G'' = (\Sigma, V \cup \{S_0\}, S_0, \mathcal{R} \cup \{S_0 \to S_0 S \mid \varepsilon\})$

Proposition 6: Alg(Σ^*) n'est pas stable par intersection.

Démonstation:
$L_1 = \{a^n b^m c^m \mid (n, m) \in \mathbb{N}\}$
$L_2 = \{a^n b^n c^m \mid (n, m) \in \mathbb{N}\}$
sont algébriques mais $L_1 \cap L_2 = \{a^n b^n c^n \mid n \in \mathbb{N}\}$ ne l'est pas.

Par exemple, L_1 est algébrique car voici une grammaire qui l'engendre :
$S \to aS \mid B$; $B \to bBc \mid \varepsilon$

Proposition 7: Alg(Σ^*) n'est pas stable par complémentaire, par différence ou par différence symétrique.

Démonstation: Conséquence directe de la non-stabilité par l'intersection.

Point Culture

Si L est un langage algébrique et K est un langage rationnel, alors l'intersection des deux est algébrique.

En partiuclier, pour tout $n \in \mathbb{N}$ et pour tout langage rationnel K,
$K \cap D_n$ est algébrique avec D_n le langage de Dyck à n parenthèses.

Ce résultat a une presque réciproque : le théorème de Chomsky-Schützenberger :

Si L est algébrique, il existe un langage rationnel K, un entier n et un morphisme alphabétique μ tel que $L = \mu(K \cap D_n)$.